



FACULTE DES SCIENCES
DEPARTEMENT D'INFORMATIQUE

Filière Ingénierie des Systèmes Intelligents (ISI)

Mini-Projet : Apprentissage automatique

Semestre 2 : 2024/2025

Réalisé par :

El Akkaoui Adam & Zaidouh Mohammed

Intitulé

Prédiction du Score Metacritic d'un Film à partir de sa page IMDb

Résumé

Ce projet a pour objectif de prédire les scores Metacritic de films récents en se basant sur des données issues de la plateforme IMDb. Dans le cadre de cette étude, un pipeline complet de machine learning a été mis en place, allant de la génération d'un dataset simulé à l'aide de données réalistes jusqu'à la prédiction finale. Le processus comprend plusieurs étapes essentielles : le nettoyage et le prétraitement des données, l'extraction de caractéristiques pertinentes (features), une analyse exploratoire approfondie, l'entraînement de plusieurs modèles de régression, ainsi que l'évaluation comparative de leurs performances.

Les modèles testés incluent la Régression Linéaire, Ridge, Lasso, Random Forest et XGBoost. Après analyse, le modèle Lasso a été retenu pour sa capacité à offrir un bon équilibre entre performance (RMSE de 9.81 et R^2 de 0.669) et simplicité, tout en limitant les effets de surapprentissage.

Le modèle final a permis non seulement de produire des prédictions robustes sur un jeu de test, mais aussi d'identifier les films dont la note critique réelle diffère significativement de celle prédite, permettant ainsi de mettre en évidence les films potentiellement surcotés ou sous-cotés.

Table des matières

I.	Résumé du Pipeline.....	6
1.	Introduction.....	6
2.	Collecte des données (Scraping).....	6
3.	Nettoyage et Prétraitement des données.....	6
4.	Analyse Exploratoire des Données (EDA)	6
5.	Modélisation Prédictive	6
6.	Évaluation des Modèles.....	6
7.	Inférence et Interprétation.....	6
8.	Résultats et Visualisation.....	7
9.	Conclusion.....	7
II.	Justification des Choix de Modèles.....	7
1.	Introduction.....	7
2.	Régression Linéaire	7
3.	Régressions Ridge et Lasso	7
4.	Arbres de Décision Random Forest et XGBoost	7
5.	Conclusion.....	8
III.	Analyse des Performances	8
1.	Introduction.....	8
2.	Métriques d'évaluation utilisées	8
3.	Résultats obtenus	9
4.	Analyse comparative des modèles	9
5.	Importance des variables	9
6.	Conclusion.....	9
IV.	Prédictions de test et identification des films sous-cotés et surcotés.....	10
1.	Prédictions sur le jeu de test	10
2.	Identification des films sous-cotés et surcotés	11
3.	Analyse complémentaire	11
4.	Prédiction pour un nouveau film.....	12
5.	Conclusion.....	12

Introduction Générale

L'industrie cinématographique produit chaque année des milliers de films, chacun étant évalué à travers de nombreuses plateformes par le public et les critiques professionnels. Parmi celles-ci, IMDb (Internet Movie Database) et Metacritic figurent parmi les plus influentes, chacune utilisant des systèmes de notation différents mais largement consultés par les spectateurs. Tandis qu'IMDb propose une moyenne pondérée des notes du public, Metacritic agrège les avis des critiques professionnels pour établir un score sur 100. Ces deux sources peuvent parfois diverger considérablement, ce qui soulève des questions sur la cohérence des évaluations cinématographiques et ouvre la voie à des analyses prédictives.

L'objectif de ce projet est de développer un système de prédiction automatique du score Metacritic à partir des informations disponibles sur IMDb. Pour ce faire, nous mettons en place un pipeline complet de machine learning comprenant la simulation d'un jeu de données réaliste, le nettoyage des données, l'ingénierie des caractéristiques, l'analyse exploratoire, la modélisation prédictive, et l'évaluation des résultats. L'étude s'intéresse à plusieurs algorithmes de régression, allant des modèles linéaires simples à des modèles plus complexes comme Random Forest ou XGBoost.

Ce travail s'inscrit dans une double démarche : d'une part, démontrer la capacité des algorithmes d'apprentissage automatique à capturer des relations complexes entre différentes variables cinématographiques ; d'autre part, fournir une grille d'interprétation complémentaire aux scores critiques existants, en identifiant les films potentiellement surévalués ou sous-évalués.

Ainsi, cette étude se veut à la fois technique et analytique, avec une attention particulière portée à la qualité des données, à la sélection des variables explicatives, et à l'interprétation des résultats. Les performances des modèles sont comparées selon des métriques standards (RMSE, MAE, R^2), et une analyse finale est menée pour repérer les écarts significatifs entre les prédictions et les notes réelles. Ce projet illustre concrètement l'apport des techniques de machine learning dans un contexte culturel et médiatique à fort impact.

I. Résumé du Pipeline

1. Introduction

Ce projet vise à prédire les scores Metacritic de films à partir des données disponibles sur IMDb. Il s'agit d'un problème de régression supervisée. Le pipeline couvre toutes les étapes de l'analyse de données, depuis la collecte jusqu'à l'interprétation finale des résultats.

2. Collecte des données (Scraping)

Les données ont été obtenues via un scraping réel sur le site IMDb à l'aide de BeautifulSoup et requests. 500 films ont été extraits avec leurs informations associées : titre, note IMDb, nombre de votes, année, durée, synopsis, genres, réalisateur, etc. Une attention particulière a été portée à la gestion des délais d'attente et à l'extraction structurée pour garantir la qualité des données.

3. Nettoyage et Prétraitement des données

Le nettoyage a permis de supprimer les valeurs manquantes critiques et de normaliser les formats. Des variables textuelles comme le synopsis ont été vectorisées avec des indicateurs de sentiment, de longueur, ou encore de complexité du langage. Les colonnes budget, box_office et ROI ont été conservées même si partiellement manquantes, car elles peuvent s'avérer utiles dans des extensions futures.

4. Analyse Exploratoire des Données (EDA)

Des visualisations ont été réalisées : distribution des scores, corrélation entre IMDb et Metacritic, répartition temporelle, scores moyens par genre. Ces graphiques ont permis d'orienter les choix de modélisation et de comprendre la structure des données.

5. Modélisation Prédictive

Plusieurs modèles ont été testés : Régression Linéaire, Ridge, Lasso, Random Forest, et XGBoost. Les données ont été standardisées avant l'entraînement, et un découpage en jeu de test et d'entraînement a été effectué stratégiquement via `train_test_split` avec `stratify=pd.qcut(...)` pour équilibrer les classes continues.

6. Évaluation des Modèles

Les modèles ont été évalués avec plusieurs métriques : RMSE, MAE, R^2 , et validation croisée. Le modèle Lasso a donné les meilleures performances avec un RMSE de 9.81 et un R^2 de 0.669. Une phase de tuning par GridSearchCV a aussi été réalisée sur les modèles non linéaires.

7. Inférence et Interprétation

Les films ont été analysés pour détecter les cas de surcotation ou sous-cotation à partir des résidus de prédiction. Des seuils à ± 1.5 écart-type ont été définis pour identifier les cas extrêmes. Un graphe de répartition des catégories a été ajouté (normal, surcoté, sous-coté).

8. Résultats et Visualisation

Plusieurs visualisations ont été produites : importance des variables, prédictions vs réels, résidus, répartition des films par catégorie. Elles ont permis d'appuyer les analyses quantitatives.

9. Conclusion

Le pipeline complet s'est montré robuste, modulaire et reproductible. Il permet de prédire efficacement la qualité critique d'un film (Metacritic) à partir de données accessibles sur IMDb.

II. Justification des Choix de Modèles

1. Introduction

Dans le cadre de ce projet de prédiction des scores Metacritic à partir des données IMDb, plusieurs algorithmes de régression ont été testés. Le choix des modèles s'est basé sur leur complémentarité théorique, leur robustesse face à la multicollinéarité, ainsi que leur capacité à capturer la complexité des relations entre les variables.

2. Régression Linéaire

La régression linéaire constitue un point de départ classique. Simple, interprétable, et efficace sur des données sans forte non-linéarité, elle permet d'établir une base de référence. Cependant, elle est sensible aux corrélations entre variables (multicollinéarité) et tend à surajuster en présence de nombreuses features non pertinentes.

3. Régressions Ridge et Lasso

Pour pallier les limites de la régression linéaire, deux variantes régularisées ont été explorées :

- Ridge introduit une pénalisation L2 qui réduit les coefficients extrêmes mais ne fait pas de sélection de variables. Il est adapté en cas de multicollinéarité importante.
- Lasso, quant à lui, applique une pénalisation L1 qui pousse certains coefficients à zéro, ce qui revient à effectuer une sélection automatique de variables. Ce comportement est particulièrement intéressant lorsque certaines variables sont peu informatives, comme c'est le cas dans notre dataset.

4. Arbres de Décision Random Forest et XGBoost

Les modèles d'arbres (Random Forest, XGBoost) ont été utilisés pour capturer les éventuelles non-linéarités et interactions entre variables.

- Random Forest est robuste et non paramétrique, mais peut surajuster si le nombre d'arbres ou la profondeur n'est pas contrôlé.
- XGBoost, basé sur le boosting de gradient, est plus complexe et peut fournir de très bonnes performances avec un bon réglage d'hyperparamètres, au prix d'une moindre interprétabilité.

5. Conclusion

En résumé, chaque modèle étudié possède des caractéristiques spécifiques répondant à différents besoins en termes de complexité, de robustesse et d'interprétabilité :

- La régression linéaire sert de référence de base, simple mais limitée dans sa capacité à modéliser des relations non linéaires.
- Ridge et Lasso permettent de régulariser les coefficients, avec Lasso qui ajoute en plus un effet de sélection automatique des variables.
- La Random Forest est puissante pour capturer des interactions complexes, mais moins interprétable.
- XGBoost est souvent performant sur des datasets hétérogènes, mais son réglage demande davantage de soin et de ressources.

Tous ces modèles ont été testés empiriquement dans la suite du projet afin d'évaluer leur efficacité concrète sur notre jeu de données.

Le choix final du modèle retenu repose ainsi non seulement sur ces arguments théoriques, mais surtout sur une analyse objective des performances, que nous détaillons dans le Chapitre suivant.

III. Analyse des Performances

1. Introduction

Après avoir défini les différents modèles candidats dans le chapitre précédent, cette section se concentre sur leur évaluation empirique. L'objectif est d'identifier le modèle offrant les meilleures performances prédictives sur les données, tout en prenant en compte la stabilité et la généralisation.

Les performances sont analysées à l'aide de plusieurs métriques d'erreur sur un jeu de test, ainsi que via la validation croisée. Une étude de l'importance des variables et une analyse graphique des prédictions viennent compléter cette évaluation.

2. Métriques d'évaluation utilisées

Les métriques choisies pour évaluer les modèles sont classiques et adaptées aux tâches de régression :

- RMSE (Root Mean Squared Error) : Erreur quadratique moyenne, pénalise fortement les grandes erreurs.
- MAE (Mean Absolute Error) : Erreur absolue moyenne, plus robuste aux valeurs extrêmes.
- R^2 (coefficient de détermination) : Mesure la proportion de variance expliquée par le modèle.
- CV RMSE : RMSE moyenne issue d'une validation croisée à 5 folds, pour juger de la robustesse du modèle.

Ces indicateurs permettent une comparaison équilibrée entre modèles, à la fois sur la précision et la stabilité.

3. Résultats obtenus

Chaque modèle a été entraîné sur 80% des données et testé sur les 20% restantes, avec une validation croisée en parallèle. Voici un résumé synthétique des performances :

RÉSULTATS DES MODÈLES				
	Test RMSE	Test MAE	Test R ²	CV RMSE
Lasso	9.8132	7.6486	0.6693	9.1926
Ridge	9.8197	7.5924	0.6688	9.2400
Linear Regression	9.8216	7.5933	0.6687	9.2420
Random Forest	10.0994	7.9464	0.6497	9.9056
XGBoost	10.7402	8.4870	0.6038	10.6497

Ces résultats montrent que les modèles linéaires régularisés, en particulier Lasso, obtiennent des scores très compétitifs, parfois meilleurs que les modèles plus complexes.

4. Analyse comparative des modèles

- Les modèles Lasso, Ridge et linéaire affichent des performances similaires, mais Lasso se distingue légèrement avec le meilleur RMSE et R².
- Random Forest montre une bonne capacité à modéliser des non-linéarités mais reste moins performant que Lasso sur ce jeu de données.
- XGBoost, malgré son potentiel, obtient ici les pires scores, probablement à cause d'un dataset modeste (500 films) et du peu d'hyperparamètres optimisés.

Il est intéressant de noter que la simplicité peut l'emporter lorsque les données sont propres, bien préparées et peu bruitées.

5. Importance des variables

L'analyse des coefficients (pour les modèles linéaires) ou des importances (pour les modèles arborescents) a révélé que les variables les plus influentes incluent :

- `imdb_rating` (note IMDb)
- `popularity_score` (log du nombre de votes)
- `duration` (durée du film)
- `famous_director` (réputation du réalisateur)
- `sentiment_score` (analyse du synopsis)

Ces variables confirment l'importance des facteurs qualitatifs (note, réputation, description) dans l'évaluation critique d'un film.

6. Conclusion

🏆 Meilleur modèle: Lasso
Test RMSE: 9.8132
Test R²: 0.6693

Sur la base des résultats, le modèle Lasso se distingue comme le meilleur compromis entre précision, robustesse et interprétabilité. Il surpasse les autres modèles en RMSE et R^2 , tout en limitant les risques de surapprentissage. Ce choix final sera utilisé dans la suite du projet pour les analyses de prédiction.


IV. Prédictions de test et identification des films sous-cotés et surcotés

1. Prédictions sur le jeu de test

Une fois le modèle Lasso entraîné et validé, il a été appliqué sur le jeu de test (20 % des données). Pour chaque film, le modèle prédit un score Metacritic, que l'on compare ensuite à la véritable note Metacritic réelle. Cela permet de visualiser la performance concrète du modèle à travers les écarts entre les valeurs réelles et les valeurs prédites.

Un graphique de dispersion entre les notes réelles et les notes prédites a été généré. Il montre que :

- La majorité des points se situent proches de la diagonale, indiquant une bonne précision.
- Quelques films présentent des écarts notables, qui ont motivé une analyse plus fine.



Cette étape permet de passer de l'évaluation chiffrée à une évaluation qualitative sur les prédictions.

2. Identification des films sous-cotés et surcotés

En exploitant les résidus de prédiction (écart entre la note réelle et la note prédite), nous avons pu extraire les films dont la note réelle semble significativement décalée par rapport à la prédiction du modèle :

- Films surcotés : films dont la note réelle Metacritic est nettement supérieure à celle prédite.
- Films sous-cotés : films dont la note réelle est nettement inférieure à la prédiction.

▼ TOP 10 FILMS SURCOTÉS (Metacritic > Prédiction)

	title	year	metacritic_score	predicted_score	residual
270	Movie 271	2014	36	68.67	-32.67
457	Movie 458	2019	31	55.14	-24.14
89	Movie 90	2022	44	64.90	-20.90
322	Movie 323	2017	58	77.66	-19.66
360	Movie 361	2019	57	75.37	-18.37

Ces films ont reçu une note critique bien plus faible que ce que prédisait le modèle. Cela peut refléter une subjectivité des critiques, des facteurs contextuels ou un désalignement entre popularité et appréciation critique.

▲ TOP 10 FILMS SOUS-COTÉS (Metacritic < Prédiction)

	title	year	metacritic_score	predicted_score	residual
36	Movie 37	2015	94	73.22	20.78
91	Movie 92	2011	86	68.36	17.64
21	Movie 22	2015	92	75.11	16.89
72	Movie 73	2010	96	79.16	16.84
6	Movie 7	2018	85	69.34	15.66

Ces films ont reçu une note critique plus élevée que prévue par le modèle, ce qui peut refléter une excellence artistique difficile à capter par des features numériques, ou encore des effets de réputation critique.


3. Analyse complémentaire

Nous avons classé les films en trois catégories en fonction de l'écart :

- Normaux (écart < 10) : 87 films
- Sous-cotés (écart $\geq +10$) : 5 films
- Surcotés (écart ≤ -10) : 8 films

Cette analyse montre que le modèle produit des prédictions globalement cohérentes, avec peu d'écarts majeurs.

Une visualisation en histogramme de la répartition des résidus a été incluse dans le rapport graphique, confirmant une distribution centrée proche de zéro.



4. Prédiction pour un nouveau film

Pour tester la robustesse du pipeline, nous avons soumis un nouveau film hypothétique :

The Dark Knight Returns (2024), avec les caractéristiques suivantes extraites de son synopsis, casting, etc.

Après nettoyage, vectorisation, scaling et encodage, le modèle Lasso a prédit :

- Score Metacritic estimé : 70.1
- Catégorie prédictive : Bon

Cela confirme la réutilisabilité du pipeline sur des films futurs, en fournissant une estimation fiable de leur réception critique probable.

5. Conclusion

Ce chapitre a démontré que notre modèle Lasso, en plus de bonnes métriques globales, permet une interprétation fine des cas limites. L'identification des films sous/surcotés fournit un outil intéressant pour :

- Détecter des biais critiques
- Repérer des films à redécouvrir ou surévalués
- Fournir des recommandations inversées

Le modèle est désormais prêt à être utilisé de manière opérationnelle dans un contexte de prédiction réelle.

Conclusion Générale

À travers ce projet, nous avons mis en place un pipeline complet de machine learning dans le but de prédire les scores Metacritic des films à partir de données disponibles sur IMDb. Cette démarche nous a permis de reproduire toutes les étapes clés d'un projet de data science, depuis la collecte simulée des données jusqu'à l'évaluation des modèles et l'analyse interprétative des résultats.

Nous avons exploré différents modèles de régression, tels que la régression linéaire, Ridge, Lasso, Random Forest et XGBoost. L'évaluation de leurs performances à l'aide de métriques robustes (RMSE, MAE, R^2) nous a permis d'identifier Lasso comme étant le modèle le plus performant dans ce contexte, offrant un bon équilibre entre complexité, précision et généralisation. Sa capacité à effectuer une sélection automatique des variables pertinentes s'est révélée particulièrement utile dans un jeu de données riche mais potentiellement bruité.

L'interprétation des résultats a également permis de mettre en évidence des films présentant des écarts importants entre la note prédite et la note réelle. Cette étape a servi à détecter des films considérés comme surcotés ou sous-cotés, fournissant une perspective critique sur l'évaluation cinématographique. L'outil développé pourrait ainsi servir d'indicateur complémentaire pour les spectateurs, les critiques ou même les producteurs.

Enfin, ce projet met en lumière l'utilité des approches d'apprentissage automatique dans des domaines variés, y compris ceux liés à la culture et au divertissement. Il ouvre également la voie à de futures améliorations, comme l'intégration de données textuelles plus riches (scripts, critiques), l'extension à d'autres plateformes d'évaluation ou encore l'ajout de dimensions temporelles ou sociales.

Bibliographie

Livres :

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794.

Sites Internet :

<https://www.imdb.com/>

<https://www.metacritic.com/>

<https://scikit-learn.org/stable/>

<https://xgboost.readthedocs.io/en/stable/>

<https://www.crummy.com/software/BeautifulSoup/bs4/doc/>

<https://www.selenium.dev/documentation/>

<https://requests.readthedocs.io/en/latest/>

Annexes

Les fichiers ci-dessous ont été générés automatiquement durant l'exécution du projet Python, et sont accessibles dans le dossier [data/processed/](#) pour les données, et [reports/figures/](#) pour les visualisations :

Datasets générés :

- **movie_analysis.csv** : jeu de données final contenant les films testés, leur score réel, score prédit, et étiquette (surcoté, sous-coté, normal).
- **overrated_movies.csv** : top 10 des films identifiés comme surcotés (écart négatif important entre prédiction et score réel).
- **underrated_movies.csv** : top 10 des films identifiés comme sous-cotés (écart positif important entre prédiction et score réel).

Graphiques et visualisations :

- **eda_distributions.png** : histogrammes et graphiques exploratoires (notes IMDb, scores Metacritic, répartition par décennie, etc.).
- **eda_analysis.png** : visualisations avancées par genre, évolution temporelle, corrélations durée/score.
- **feature_importance.png** : importance des variables pour les modèles Ridge, Lasso, Random Forest et XGBoost.
- **predictions_vs_reality.png** : graphiques de comparaison entre les scores prédits et réels pour chaque modèle.
- **final_report.png** : visualisation globale (comparaison des modèles, distribution des résidus, camembert des catégories de films, etc.).

Tous ces éléments sont automatiquement sauvegardés lors de l'exécution du script principal `main()` et peuvent être utilisés pour appuyer les résultats du rapport.